Домашнее задание по методам оптимизации (линейное программирование)

Оптимизация размещения двух типов инференс-сервисов: «лёгкие» и «тяжёлые»

Лепустин Дмитрий Сергеевич Б24-517

Исходные данные:

На узлах кластера размещаются два типа сервисов: «лёгкие» и «тяжёлые» инференс-сервисы. Суммарный доступный объём памяти на узлах — 16 условных единиц, суммарное число доступных vCPU — 18 условных единиц. Каждый экземпляр «лёгкого» сервиса приносит эффект 2 условные единицы и потребляет 2 единицы памяти и 1 единицу vCPU. Каждый экземпляр «тяжёлого» сервиса приносит эффект 3 условные единицы и потребляет 2 единицы памяти и 3 единицы vCPU. Требуется определить количество развёрнутых экземпляров каждого типа сервиса, максимизирующее суммарный эффект при соблюдении обоих ограничений.

Часть А. Формализация

Пусть:
x - число экземпляров «лёгкого» сервиса,
y - число экземпляров «тяжёлого» сервиса.
Оба значения целы и неотрицательны.

Целевая функция:

$$\max(2x + 3y)$$

Коэффициенты 2 и 3 – эффект каждого сервиса в условных единицах.

Ограничения:

$2x + 2y \leq 16$
$x + 3y \leq 18$
$x, y \geq 0; x, y \in Z$

Каноническая форма:

Введем дополнительные переменные u и v, означающие не использованную память и vCPU соответственно.

$2x + 2y + u = 16$
$x + 3y + v = 18$
$x, y, u, v \geq 0$

Часть Б. Геометрическое решение

Рассмотрим плоскость (x, y). Прямые ограничений:

1. $2x + 2y = 16$ - ограничение по памяти

2. $x + 3y = 18$ – ограничение по vCPU

Область допустимых решений - четырёхугольник с вершинами: (0, 0); (0, 6); (3, 5); (8, 0)

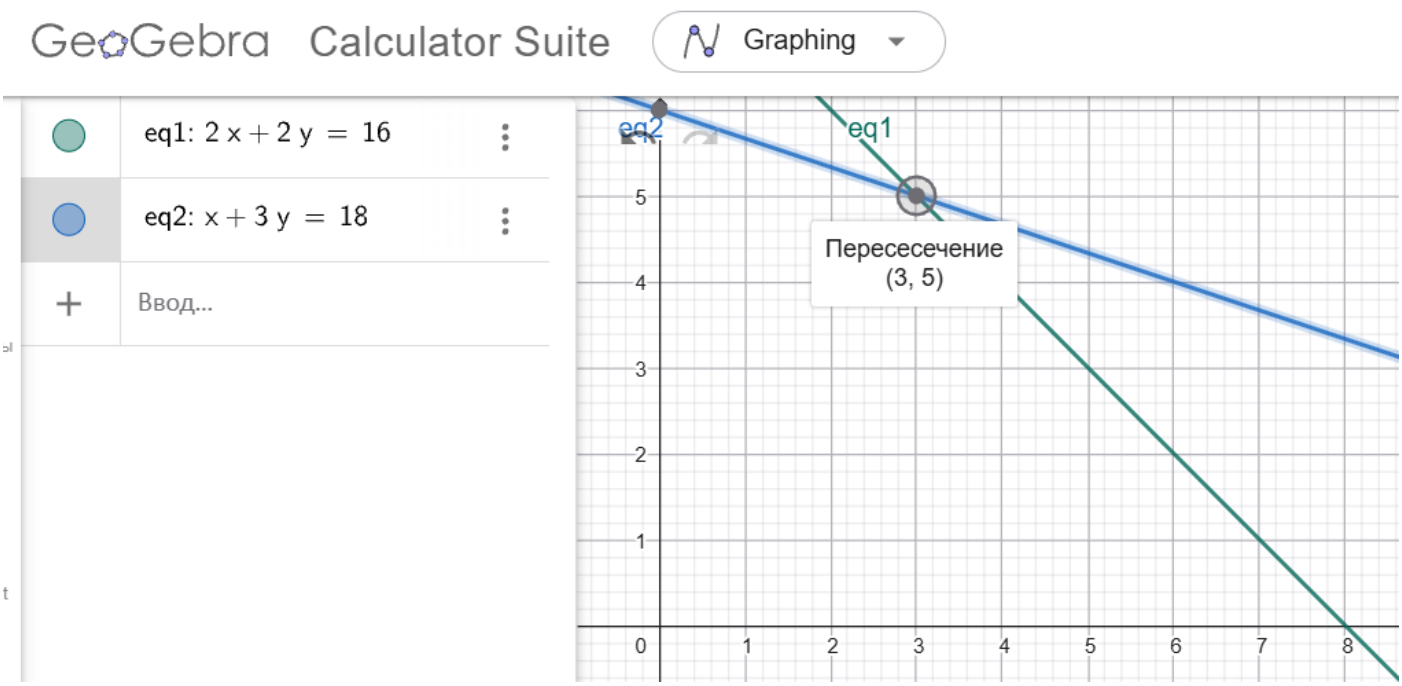


Рис. 1: Область допустимых решений

Вектор целевой функции c = (2, 3) – он означает направление эффективности использования ресурсов.
Проверим значения эффективности использования ресурсов в каждой точке, соприкасающейся с ограничением:
(0, 0) * (2, 3) = 0 * 2 + 0 * 3 = 0
(0, 6) * (2, 3) = 0 * 2 + 6 * 3 = 18
(3, 5) * (2, 3) = 3 * 2 + 5 * 3 = 21
(8, 0) * (2, 3) = 8 * 2 + 0 * 3 = 16

В точке (3, 5) ресурсы используются наиболее эффективно.
Вывод:

Оптимальное решение – 3 лёгких сервиса и 6 тяжёлых.

Часть B. Базисные решения и словари

Обозначим:

- x_1— число экземпляров «лёгкого» сервиса;
- x_2— число экземпляров «тяжёлого» сервиса;
- s_1— остаток памяти;
- s_2— остаток vCPU.

Каноническая форма

$$\begin{cases} 2x_1 + 2x_2 + s_1 = 16, \\ x_1 + 3x_2 + s_2 = 18, \\ x_1, x_2, s_1, s_2 \geq 0. \end{cases}$$

Целевая функция:

$$Z = 2x_1 + 3x_2 \to \max.$$

Всего переменных 4, уравнений 2, поэтому базисных решений может быть:

$$\binom{4}{2} = 6.$$

Перечислим все базисные решения

№	Небазисные	Базисные	Значения	Допустимо?	Вершина ОДР
1	$s_1 = 0, s_2 = 0$	x_1, x_2	$x_1 = 3, x_2 = 5, s_1 = 0, s_2 = 0$	Да	$(3; 5)$
2	$x_1 = 0, x_2 = 0$	s_1, s_2	$s_1 = 16, s_2 = 18$	Да	$(0; 0)$
3	$x_1 = 0, s_1 = 0$	x_2, s_2	$x_2 = 8, s_2 = -6$	Нет, $s_2 < 0$	—
4	$x_1 = 0, s_2 = 0$	x_2, s_1	$x_2 = 6, s_1 = 4$	Да	$(0; 6)$
5	$x_2 = 0, s_1 = 0$	x_1, s_2	$x_1 = 8, s_2 = 10$	Да	$(8; 0)$
6	$x_2 = 0, s_2 = 0$	x_1, s_1	$x_1 = 18, s_1 = -20$	Нет, $s_1 < 0$	—

Допустимые базисные решения соответствуют вершинам ОДР:

$$(0; 0),\ (8; 0),\ (3; 5),\ (0; 6).$$

Оптимальная вершина — $(3; 5)$.

Словарь для стартовой допустимой вершины

Стартовая вершина:

$$x_1 = 0,\ x_2 = 0.$$

Небазисные переменные: x_1, x_2.
Базисные переменные: s_1, s_2.

Словарь:

$$s_1 = 16 - 2x_1 - 2x_2,$$
$$s_2 = 18 - x_1 - 3x_2,$$
$$Z = 2x_1 + 3x_2.$$

В точке $x_1 = x_2 = 0$:

$$s_1 = 16,\ s_2 = 18,\ Z = 0.$$

Словарь для оптимальной вершины

Оптимальная вершина:

$$x_1 = 3,\ x_2 = 5.$$

Небазисные переменные: s_1, s_2.
Базисные переменные: x_1, x_2.

Выразим базисные переменные через небазисные:

$$x_1 = 3 - \frac{3}{4}s_1 + \frac{1}{2}s_2,$$
$$x_2 = 5 + \frac{1}{4}s_1 - \frac{1}{2}s_2.$$

Целевая функция:

$$Z = 21 - \frac{3}{4}s_1 - \frac{1}{2}s_2.$$

В точке $s_1 = s_2 = 0$:

$$x_1 = 3,\ x_2 = 5,\ Z = 21.$$

Коэффициенты при небазисных переменных s_1, s_2 в целевой функции отрицательны, значит дальнейшее увеличение s_1 или s_2 уменьшает суммарный эффект. Следовательно, вершина $(3; 5)$ оптимальна.

Итоговый ответ

Оптимальный план:

$x_1 = 3$ экземпляра «лёгкого» сервиса,
$x_2 = 5$ экземпляров «тяжёлого» сервиса.

Максимальный суммарный эффект:

$$Z_{\max} = 2 \cdot 3 + 3 \cdot 5 = 6 + 15 = 21.$$

Оба ресурса используются полностью:

$$2 \cdot 3 + 2 \cdot 5 = 6 + 10 = 16,$$
$$3 + 3 \cdot 5 = 3 + 15 = 18.$$

Ответ: нужно развернуть **3 «лёгких»** и **5 «тяжёлых»** экземпляров сервиса. Максимальный суммарный эффект равен **21 условной единице**.